



北京師範大學  
BEIJING NORMAL UNIVERSITY

# 计算语言学的数学基础

## (3) 概率论与信息论

---

王予沛

2025 年 3 月 10 日

北京师范大学数字人文系



## ① 概率论基础



## ② 信息论基础



# 概率论基础

---



# 概率论基础

- 概率是从事件空间到区间  $[0, 1]$  的映射。
- 概率的两个视角
  - 频率视角：重复实验，记录结果。例如扔骰子。
  - 贝叶斯视角：根据已知信息，更新对事件发生可能的信心，如天气预报。这时概率可理解为对某件事情的信念度（degree of belief）。
- 概率分布
  - 离散型随机变量  $\rightarrow$  概率质量函数
  - 连续型随机变量  $\rightarrow$  概率密度函数
- 归一性：概率质量函数或概率密度函数在所有可能取值上的求和或积分为 1。
- 条件概率：在已知某些事件发生的条件下，事件发生的概率。
- 独立性：两个事件的发生互不影响。
- 期望：随机变量的加权平均值： $E(X) = \sum_i x_i p_i$ 。
- 方差：随机变量与其期望的差的平方的期望：
$$\text{Var}(X) = E((X - E(X))^2)。$$



# 信息论基础

---



# 惊讶度

你扔一次硬币，你的朋友猜测硬币落地后花面朝上。如果你的朋友猜对了，你或许不会太惊讶，因为硬币落地后花面朝上的概率是 0.5。

但如果你投掷一枚骰子，你的朋友猜测骰子落地后点数是 6。如果你的朋友猜对了，你可能会更加惊讶，因为骰子落地后点数是 6 的概率是  $1/6$ 。

我们发现，概率越小的事件，发生时带来的惊讶度越大。我们是否可以找到一个衡量惊讶度的函数，来描述事件发生的惊讶程度？

# 惊讶度

我们想定义的描述惊讶度的函数应该满足以下条件：

- 事件发生的概率越小，惊讶度越大；事件发生的概率越大，惊讶度越小。
- 当一件事情的概率比另一件事情的概率小  $n$  倍时，它的惊讶度应该比另一件事情大  $n$  倍。例如你的朋友连续三次猜对了骰子的点数  $\{1, 3, 6\}$ ，你应该比猜对了单次惊讶 3 倍。

严格来说，惊讶度应该是一个非负，和事件发生的概率负相关，并且在概率需要做乘法的时候，惊讶度做加法。

我们考虑一个事件  $x$ ，它的概率为  $p(x)$ 。我们定义它的惊讶度为：

$$h(x) = \log \frac{1}{p(x)}$$

将其平均，我们将得到对一个概率分布的总体惊讶度：

$$H = \sum_{x \in \mathcal{X}} p(x) \log \frac{1}{p(x)}$$

我们将这个值称为概率分布的熵 (entropy)。

## 从贝叶斯视角看惊讶度和熵

假设有一枚硬币非常地不均匀，它有 99% 的概率正面朝上，1% 的概率反面朝上。但我们事先不知道这一点，我们先验地认为硬币是均匀的，即正面朝上的概率是 50%。

我们扔 10 次硬币，结果是 10 次正面朝上，这大大出乎我们的意料。

如果这枚硬币是均匀的，我们扔 10 次硬币，结果是 10 次正面朝上的概率是  $0.5^{10} \approx 0.001$ ，这件事情的惊讶度是  $\log \frac{1}{0.001} \approx 7$ ；而实际上由于硬币非常不均匀，这个概率是  $0.99^{10} \approx 0.9$ ，这件事情的惊讶度是  $\log \frac{1}{0.9} \approx 0.1$ 。

我们如此惊讶，并不是因为发生了什么奇怪的事情，而是因为我们事先的信念是错误的。



# 交叉熵

现在，我们定义一个指标，当随机变量的真实分布为  $P$ ，但我们对该变量的信念是分布  $Q$  时我们的惊讶程度。

$$H(P, Q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{1}{q(x)} \quad (1)$$

我们将这个值称为**交叉熵** (cross entropy)。交叉熵可用于衡量两个概率分布之间差异的指标。**注意到，交叉熵不能关于  $P$  和  $Q$  对称。**

显然，只要我们用错误的分布来描述真实分布，我们在抽样观测时就一定会对结果感到惊讶。因此交叉熵就一定大于熵。

$$H(P, Q) \geq H(P)$$

等号成立当且仅当  $P = Q$ 。

## 例子：均匀和非均匀硬币

当我们认为硬币均匀  $P = \{0.5, 0.5\}$  但实际硬币不均匀  $Q = \{0.99, 0.01\}$  时，投掷一次硬币的交叉熵为：

$$H(P, Q) = 0.99 \log \left( \frac{1}{0.5} \right) + 0.01 \log \left( \frac{1}{0.5} \right) \approx 0.7$$

当我们认为硬币不均匀  $P = \{0.99, 0.01\}$  但实际硬币均匀  $Q = \{0.5, 0.5\}$  时，投掷一次硬币的交叉熵为：

$$H(P, Q) = 0.5 \log \left( \frac{1}{0.99} \right) + 0.5 \log \left( \frac{1}{0.01} \right) \approx 2.3$$

从本例可见，我们对某一个不符合真实分布的信念越自信，实验结果越出乎意料，我们就会越惊讶，或者说，错误的惩罚越重。

## 例子：垃圾邮件分类

假设我们想开发一个简单的邮件分类系统，用于判断收到的邮件是“正常邮件”还是“垃圾邮件”。这是一个典型的二分类问题。我们用 0 表示正常邮件，用 1 表示垃圾邮件。

假设我们有一个已训练好的模型，对 5 封测试邮件进行了预测，得到了以下结果：

邮件编号	真实标签	模型预测
邮件 1	0(正常)	0.2 (20% 可能是垃圾邮件)
邮件 2	0(正常)	0.1 (10% 可能是垃圾邮件)
邮件 3	1(垃圾)	0.7 (70% 可能是垃圾邮件)
邮件 4	1(垃圾)	0.9 (90% 可能是垃圾邮件)
邮件 5	0(正常)	0.4 (40% 可能是垃圾邮件)

## 例子：垃圾邮件分类

在实际应用时，我们有时会对所有样本的交叉熵取平均，得到一个平均交叉熵。在本例中，我们这样计算<sup>1</sup>：

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

其中， $N$  是样本数量， $y_i$  是真实标签（代表真实分布）， $p_i$  是模型预测的概率（代表模型对垃圾邮件分类的“信念”分布）。

- 邮件 1（真实标签 = 0，预测概率 = 0.2）：  
模型预测正常邮件的概率为 0.8，代入公式：

$$-[0 \cdot \log(0.2) + (1 - 0) \cdot \log(0.8)] = -\log(0.8) = 0.223$$

- 邮件 2（真实标签 = 0，预测概率 = 0.1）：

$$-[0 \cdot \log(0.1) + (1 - 0) \cdot \log(0.9)] = -\log(0.9) = 0.105$$

---

<sup>1</sup>前面出现负号是因为  $\log(\frac{1}{p}) = -\log(p)$ 。由于是二分类，所以概率只有  $p$  和  $1 - p$  两种情况。

## 例子：垃圾邮件分类

- 邮件 3（真实标签 = 1，预测概率 = 0.7）：

$$-[1 \cdot \log(0.7) + (1 - 1) \cdot \log(0.3)] = -\log(0.7) = 0.357$$

- 邮件 4（真实标签 = 1，预测概率 = 0.9）：

$$-[1 \cdot \log(0.9) + (1 - 1) \cdot \log(0.1)] = -\log(0.9) = 0.105$$

- 邮件 5（真实标签 = 0，预测概率 = 0.4）：

$$-[0 \cdot \log(0.4) + (1 - 0) \cdot \log(0.6)] = -\log(0.6) = 0.511$$

最后，计算平均损失：

$$\text{平均损失} = \frac{0.223 + 0.105 + 0.357 + 0.105 + 0.511}{5} = 0.260$$

## 例子：垃圾邮件分类

交叉熵损失值越小，表示模型预测效果越好：

- 当模型对正常邮件预测的“正常概率”接近 1 时，损失值接近 0
- 当模型对垃圾邮件预测的“垃圾概率”接近 1 时，损失值接近 0
- 当模型预测错误（信念和真实分布不一致）时，损失值会增大

在我们的例子中：

- 邮件 2 和邮件 4 的损失值最小 (0.105)，说明模型对这两封邮件的预测最准确
- 邮件 5 的损失值最大 (0.511)，说明模型对该邮件的预测信心不足

总的平均损失为 0.260，这个数值可以与其他模型的损失进行比较，帮助我们选择更好的模型。

我们发现，交叉熵带来的惊讶，有两个成分：

- 真实分布  $P$  本身的不确定性；
- 我们用  $Q$  描述  $P$  时带来的惊讶。

我们希望将二者剥离开，特别是希望仅仅考虑我们用  $Q$  描述  $P$  时带来的惊讶，由于真实分布  $P$  本身的不确定性已经可以用熵来描述，我们只需要考虑交叉熵与熵的差值。

$$D_{KL}(P \parallel Q) = H(P, Q) - H(P)$$

我们将这个值称为**KL 散度** (KL divergence)。同样地，KL 散度不能关于  $P$  和  $Q$  对称。